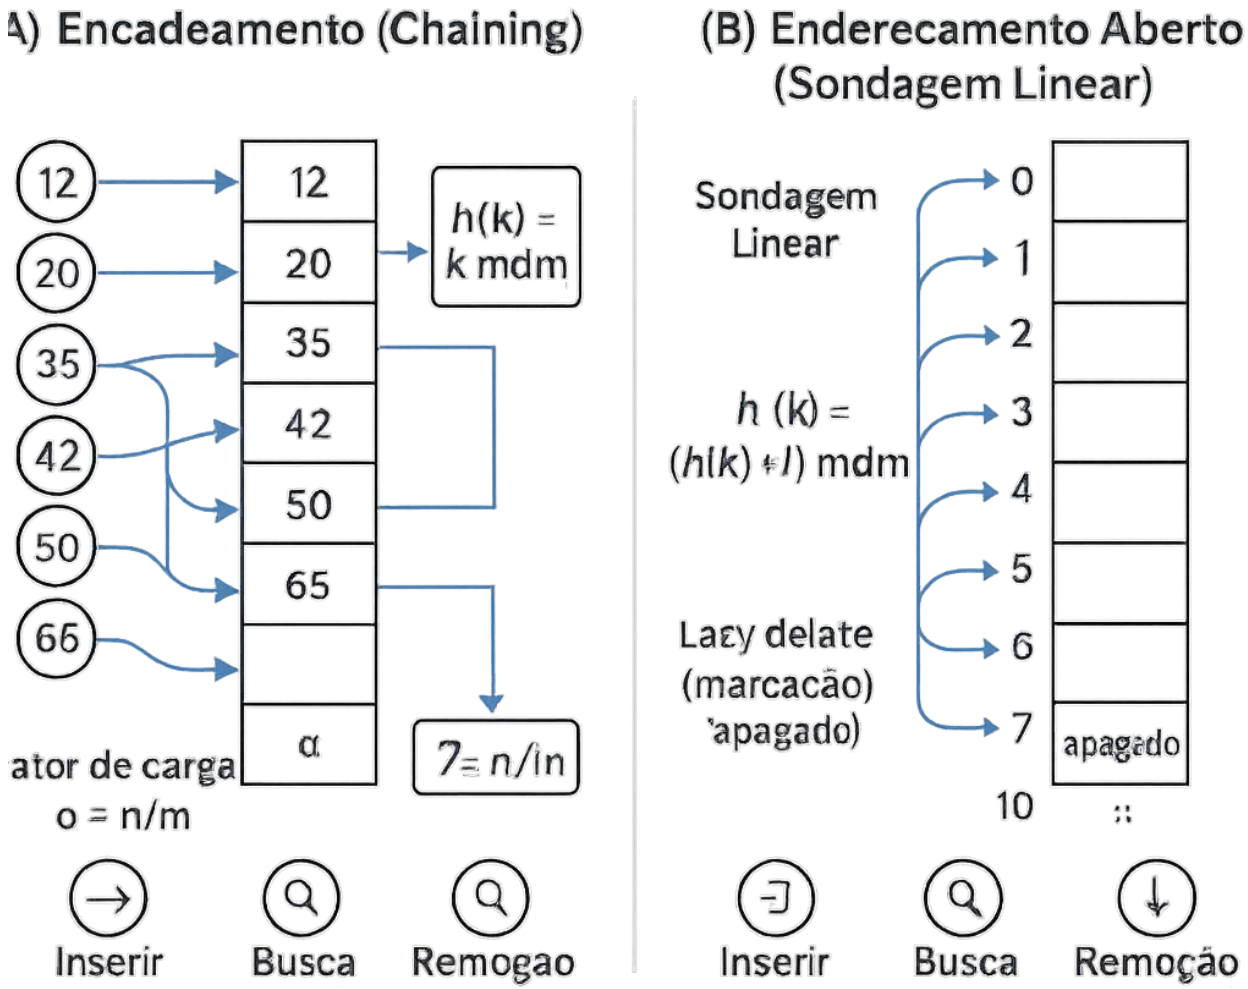
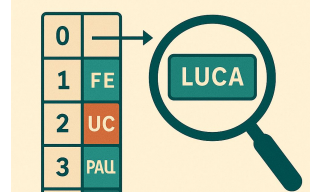
Tabela Hash

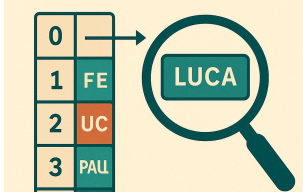

A) Encadeamento (Chaining)
12
20
35
42
50
66
12
20
35
42
50
65
α
h(k) = k mdm
ator de carga
o = n/m
Inserir
Busca
Remogao
(B) Enderecamento Aberto (Sondagem Linear)
Sondagem Linear
h (k) = (h(k) + l) mdm
Lacy delate (marcacão) 'apagado)
0
1
2
3
4
5
6
7
10
apagado
Inserir
Busca
Remoção



Hashing

Motivação

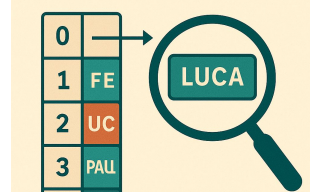
- **Tabela de símbolos:** utiliza procedimentos para busca, inserção e exclusão.
  - A tabela de símbolos **não considera ordenação**.
- Seja T uma tabela e um registro x com uma chave (símbolo) e um dado. Precisamos implementar:
  - Insert (T, x)
  - Delete (T, x)
  - Search(T, x)
- Tabela hash será utilizada, onde as operações ocorrem em O(1).



Hashing

Tabela Hash ou Tabela de Dispersão

- Estrutura de dados que implementa uma tabela de símbolos ou dicionário.
- Essa estrutura de dados permite mapear chaves em dados ou valores associados.
- Trata-se de uma coleção de itens armazenados que são facilmente localizados a partir das chaves associadas a tais itens.



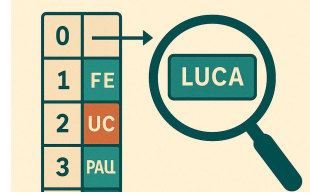
Hashing

Tabela Hash ou Tabela de Dispersão

- Amplifica a ideia de acesso aos dados utilizada, por exemplo, em vetores (listas, tuplas, strings,..)
  - O tamanho da lista pode aumentar mas as operações de atribuição e acesso via índice gasta a mesma quantidade de tempo, ou seja,O(1).

```
1   L=[0,0,0,0,0]
2   L[0]=2
3   L[1]=3
4   L[4]=3
```

```
[2, 3, 0, 0, 3]
```



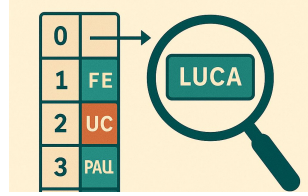
Hashing

Tabela Hash ou Tabela de Dispersão

- Apresenta complexidade O(1) no tempo de busca por um dado item da tabela, **considerando algumas hipóteses**.
  - Essa complexidade de tempo pode ser O(n) no pior caso.

```
1   L=[0,0,0,0,0]
2   L[0]=2
3   L[1]=3
4   L[4]=3
```

```
[2, 3, 0, 0, 3]
```



Tabelas com Endereçamento Direto

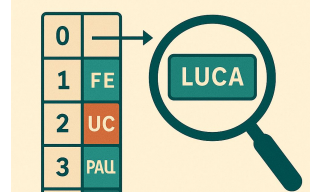
Hipóteses

- Suponha que:
  - Todas as chaves (keys) são números naturais (grandes) num intervalo 0...m-1
  - As chaves são distintas
  - Podemos definir um vetor T[0..m-1] tal que

    if $x \in T$ && key[x] = i

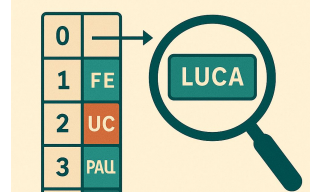
    T[i] = x

    else T[i] = NULL



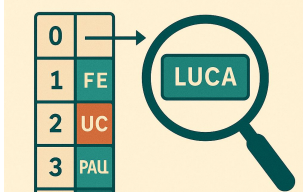
Tabelas com Endereçamento Direto

- Funcionam apropriadamente quando o intervalo das chaves é pequeno.
- Exemplo: Considere chaves que são inteiros de 32-bit.
    - A tabela de endereçamento direto terá 2^{32} > 4 bilhões de entradas.
    - Se memória não for um problema, o tempo para inicializar os elementos em NULL pode ser proibitivo.



Tabelas com Endereçamento Direto

- Alternativa para intervalos de chaves maiores:
    - Transformação de Chave – Hashing
- Hashing Mapear chaves em um intervalo menor 0...m-1
- **Spoiler: colisões irão ocorrer!!**

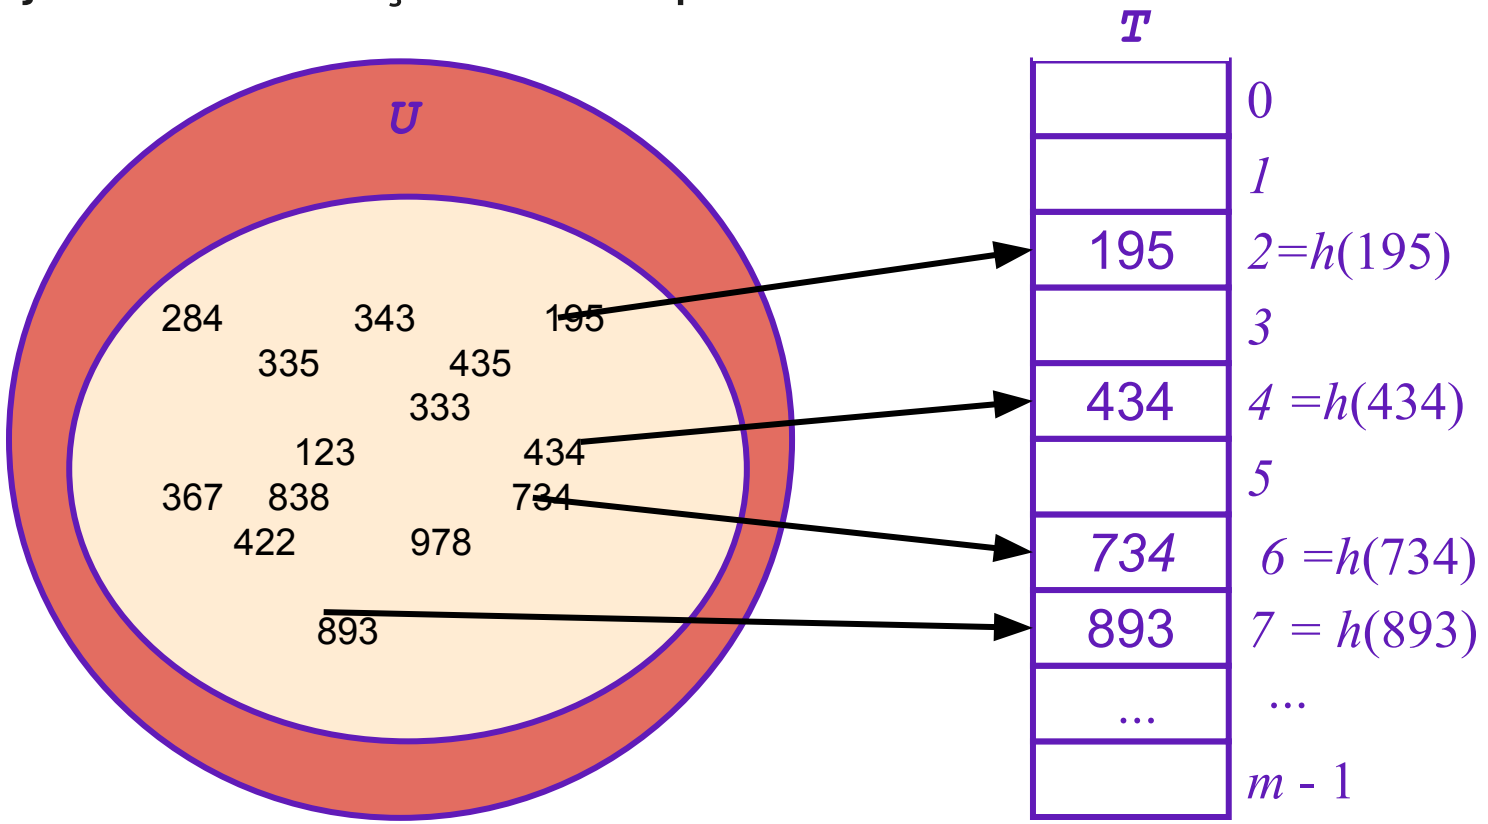


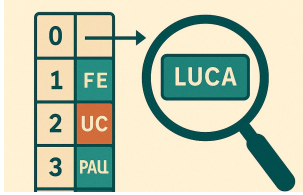
Tabelas com Endereçamento Direto

Transformação de Chave - Hashing

- Alternativa para intervalos de chaves maiores.
- Recebe como entrada itens a partir de um conjunto de itens com tamanho variados, retornando como saída uma chave que pertence a uma coleção de índices com tamanho fixo.

- Mapeia o universo de chaves possíveis U para um conjunto {0,...,m-1} usando funções de espalhamento (hash function).

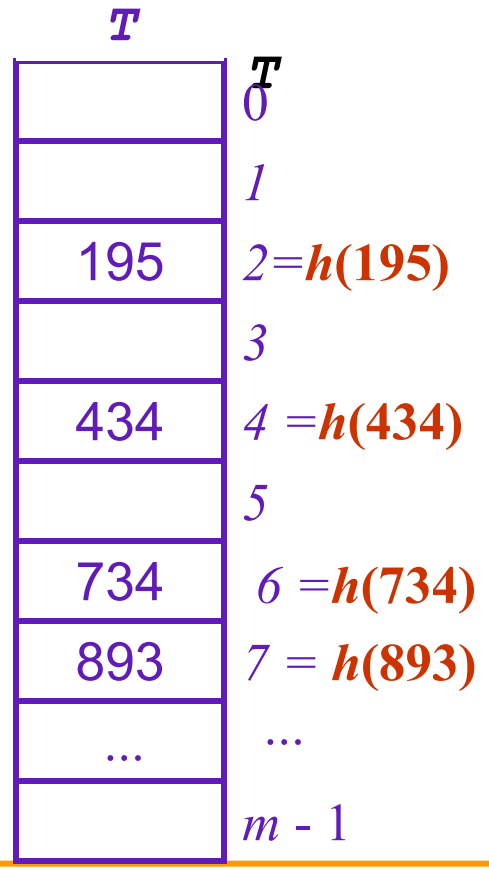




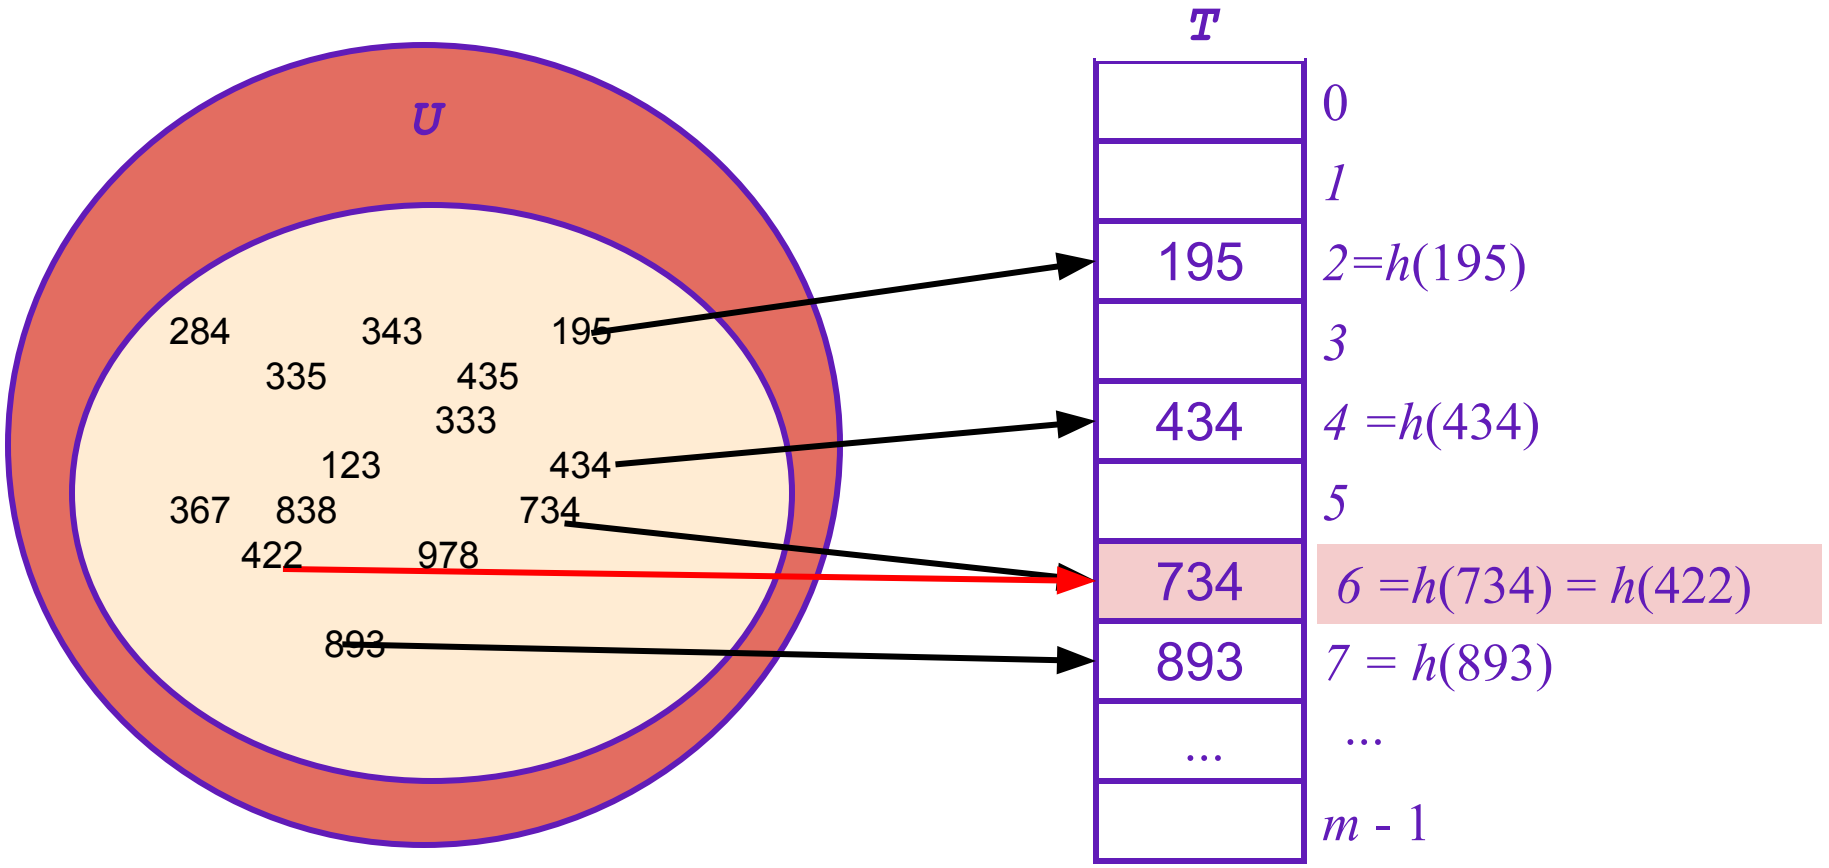
Hashing

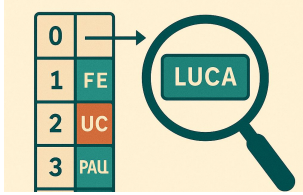
Hash Function ou Função de Espalhamento.

- Trata-se de uma função que mapeia os itens com tamanho variado em índices com tamanho fixo.
- A função de espalhamento recebe qualquer item na coleção e retorna um inteiro dentro do intervalo dos índices, isto é, entre 0 e m-1



- **Colisões** podem acontecer





Função de Espalhamento

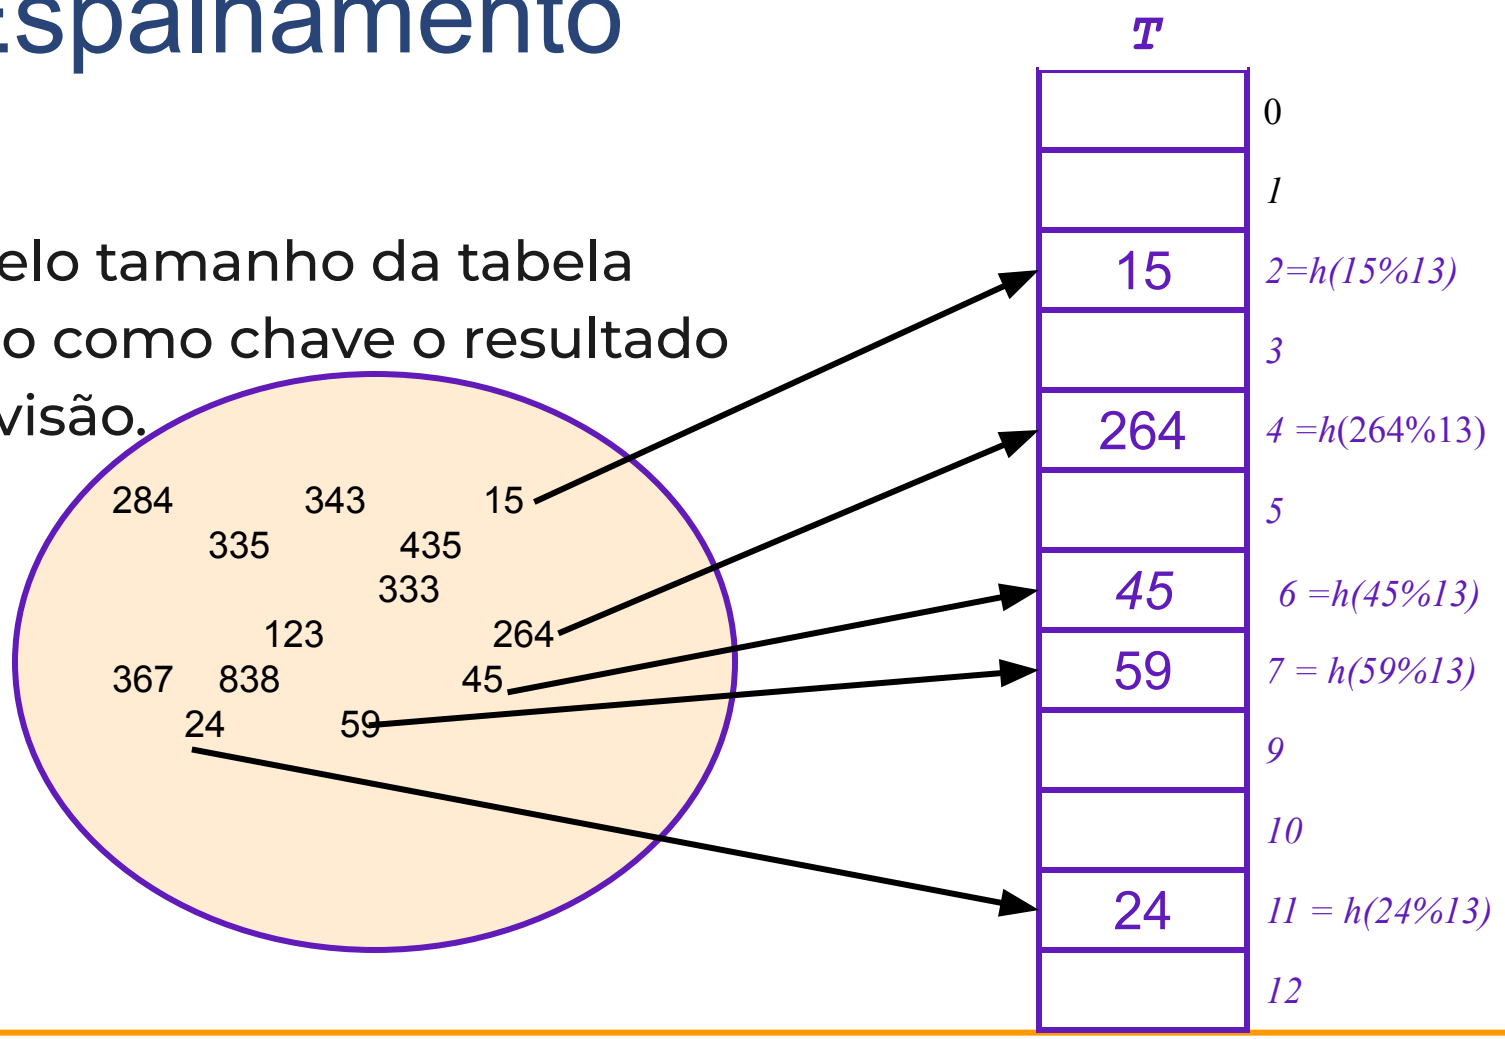
- Ajuda a tratar colisões.
- A escolha de uma função hash adequada se torna fundamental:
  - Deve distribuir as chaves uniformemente nas entradas de T.
  - Não deve depender de padrões dos dados.
- Técnicas heurísticas podem ser utilizadas:
  - Método da divisão

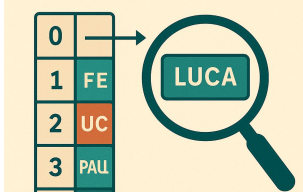
Função de Espalhamento

Método da Divisão

- Divide o item k pelo tamanho da tabela hash e retornando como chave o resultado do resto dessa divisão.

h(k)=k%m





Função de Espalhamento

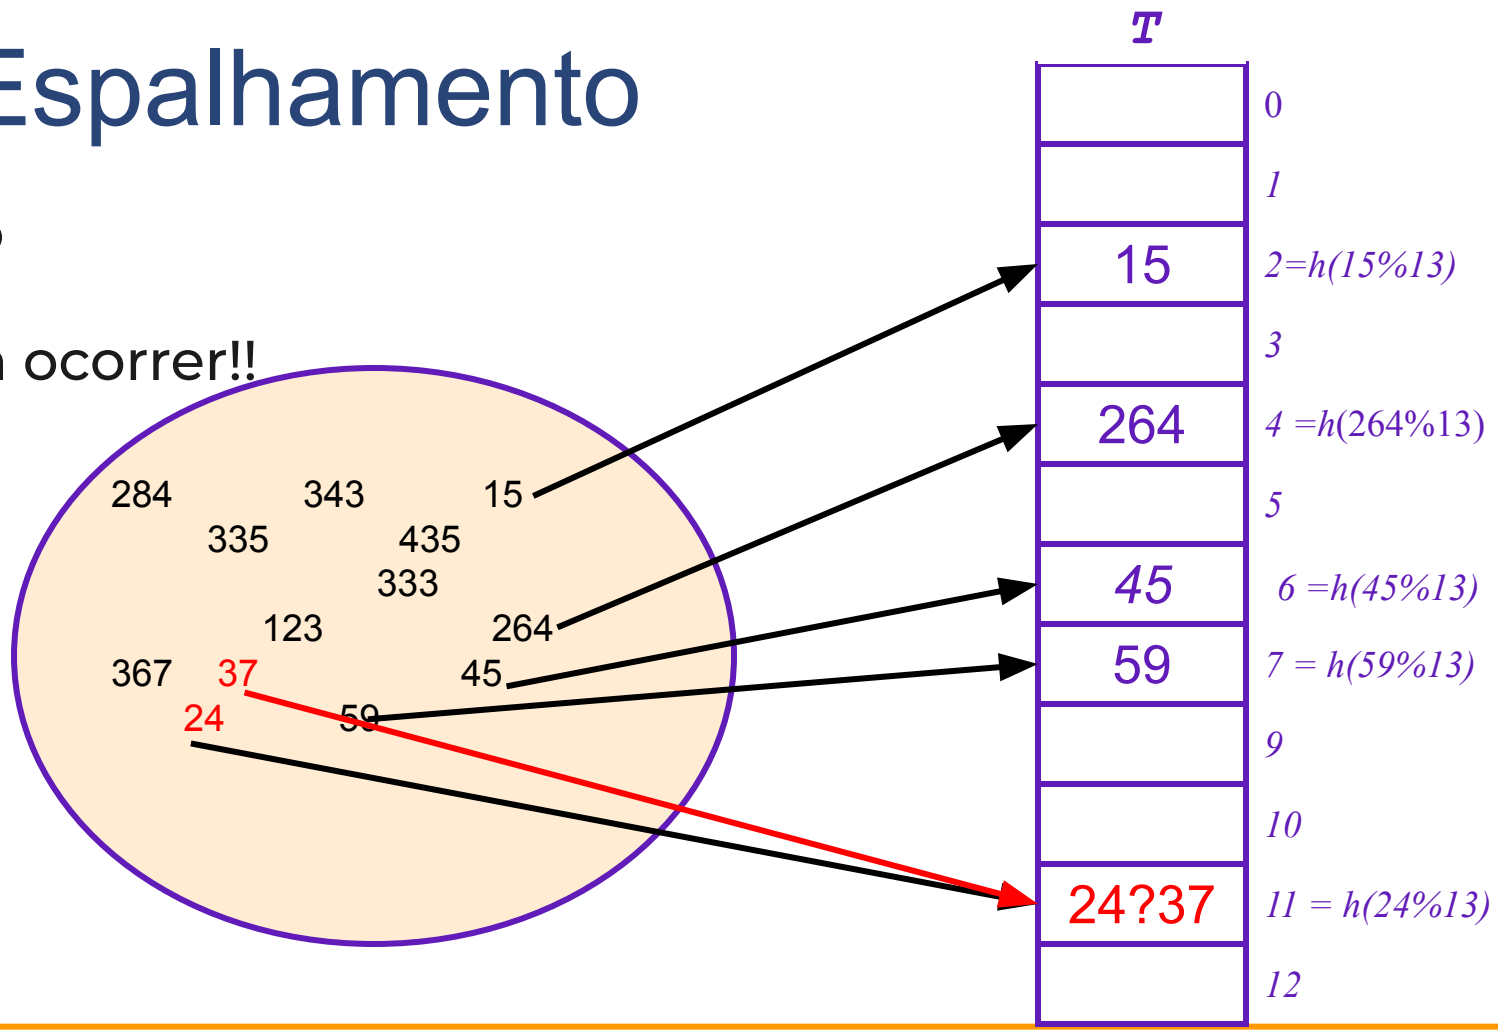
Método da Divisão

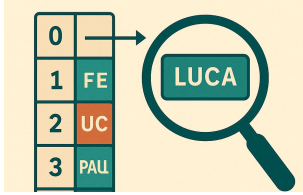
- A busca em uma tabela hash necessita apenas do valor a ser procurado, o tamanho da tabela e a função de espalhamento.
- A busca será O(1) já que gasta um tempo constante para executar as operações na função de espalhamento.

Função de Espalhamento

Método da Divisão

- Colisões podem ocorrer!!

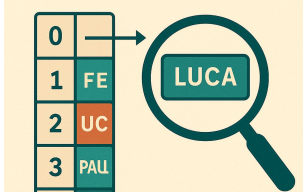




Função de Espalhamento

Método da Divisão

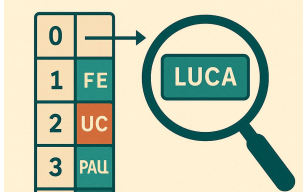
- Desvantagem:
  - Não escolher um valor de m que tenha um pequeno divisor d.
  - Isso levará a uma maior incidência de chaves que são congruente módulo d, afetando a uniformidade desejada nas atribuições.
- Solução:
  - Escolher um tamanho de tabela com m= número primo.



Função de Espalhamento

Função de Espalhamento Perfeita

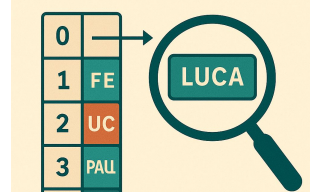
- Função de espalhamento que mapeia cada item para uma única posição na tabela hash.
  - Funciona quando a coleção de itens não será alterada.
- Na prática, colisões podem ocorrer para um conjunto qualquer de itens já que se torna mais complexo encontrar uma função de espalhamento perfeita.



Função de Espalhamento

Função de Espalhamento Perfeita

- Uma boa função de espalhamento não precisa ser perfeita mas deve minimizar as colisões.
- Solução: Aumentar o tamanho da tabela hash
  - Impraticável para o tratamento de um grande volume de dados.
- Propor outras funções de espalhamento:
  - Método do quadrado do meio
  - Método de Folding



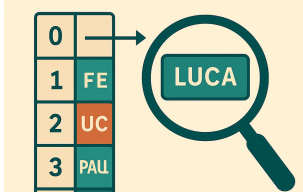
Função de Espalhamento

Método do Quadrado do Meio

- Eleva-se o item ao quadrado seguido pela remoção de alguns dígitos do resultado obtido.
- Exemplo: k=264

$k^2=(264)^2 = 69696 = 6996$...o dígito do meio foi removido

$6996\%13 = 2$



Função de Espalhamento

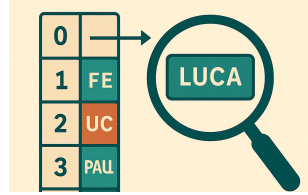
Método de Folding

- Dividi o item em partes com mesmo tamanho, exceto pelo último pedaço.
- Soma os valores dessas partes para gerar o novo item para aplicação da função de espalhamento.
- Exemplo: Considere k = 456375123-09 um cpf

45,63,75,12,30,9

45+63+75+12+30+9 = 234

234%13 = 0



Função de Espalhamento

Método de Folding

- Podemos trocar a ordem dos valores dentro de cada parte
- Exemplo: Considere k = 456375123-09 um cpf

45,63,75,12,30,9

54,36,57,21,30,9

54+36+57+21+30+9 = 207

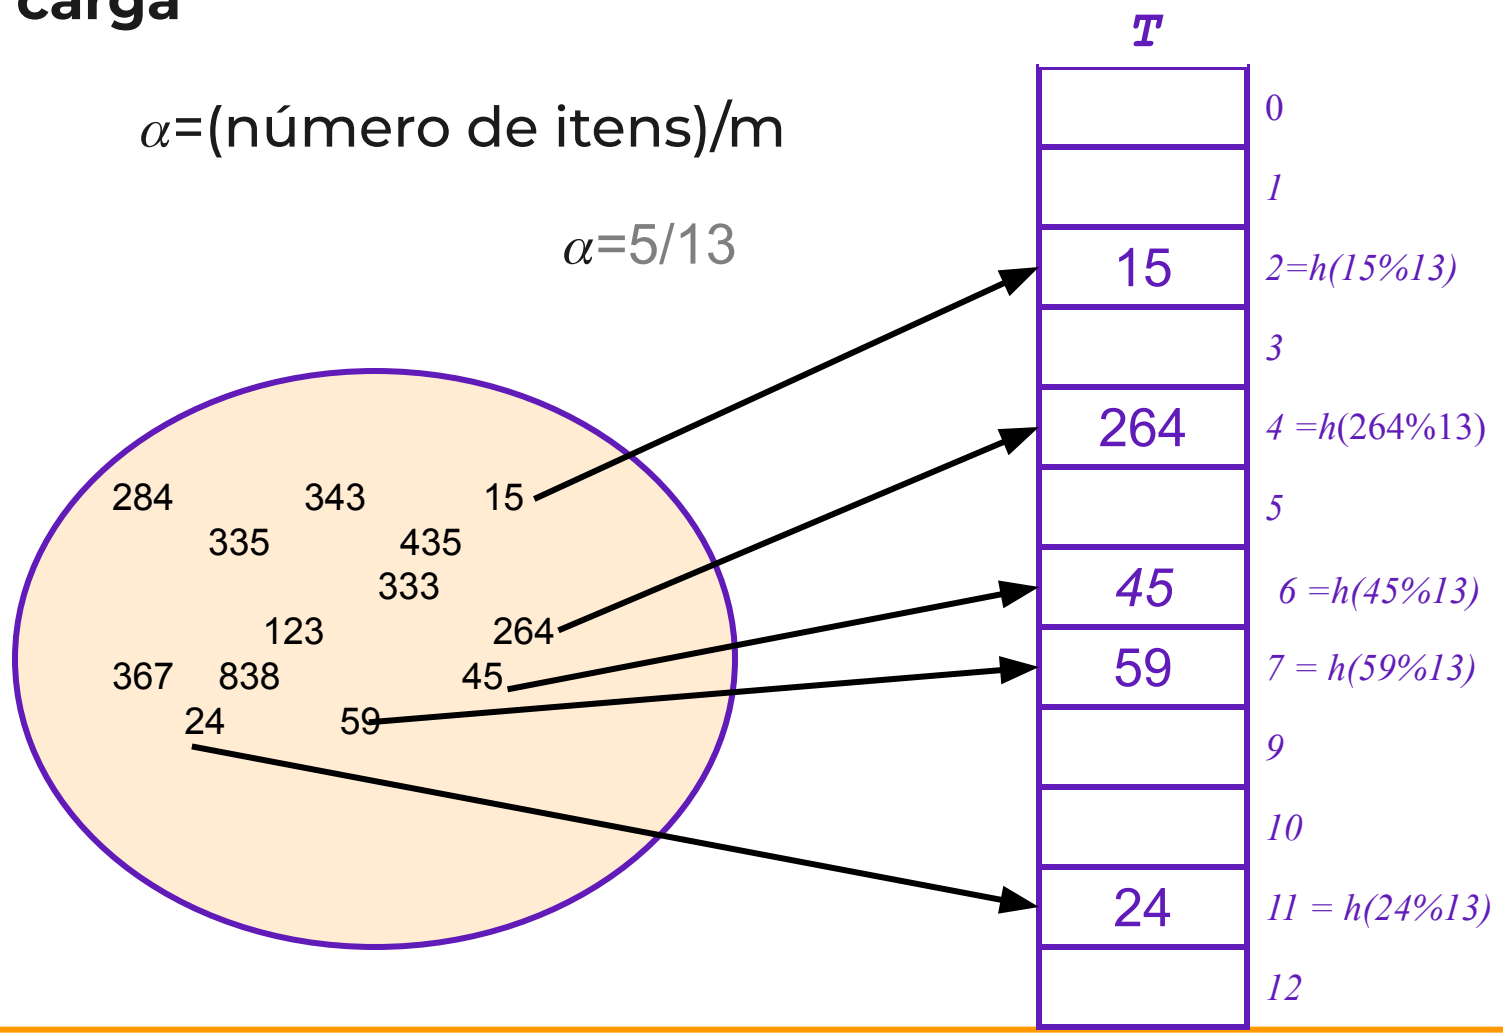
207%13 = 12

Função de Espalhamento

Fator de carga

α=(número de itens)/m

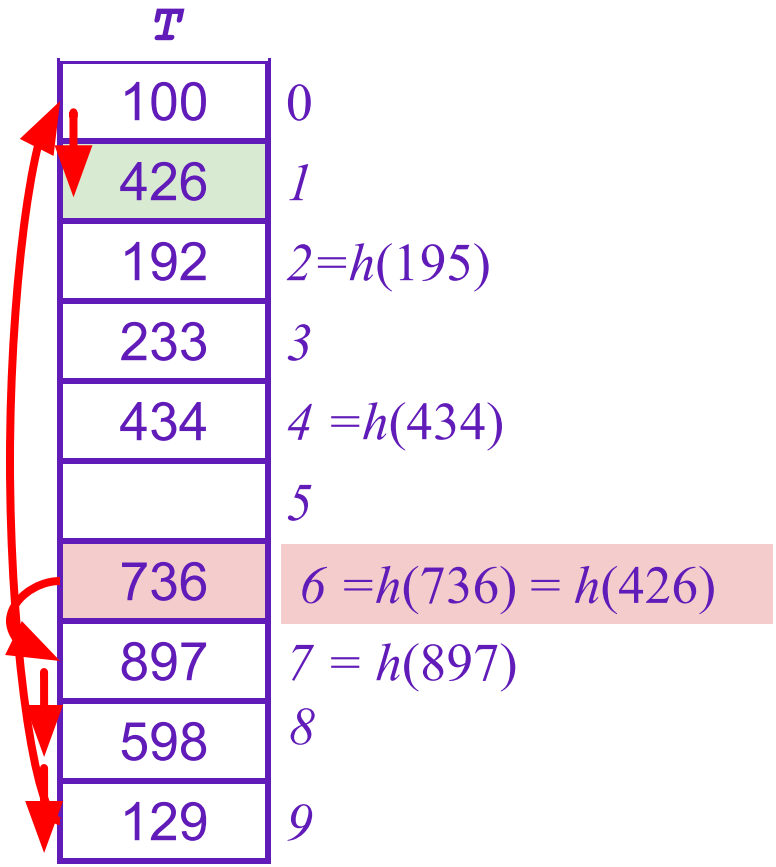
α=5/13



Tratamento de Colisões

Endereçamento aberto

- Busca até encontrar uma posição aberta (vazia) na tabela
- A busca varre uma a uma as posições seguintes aquela onde ocorrer a colisão até encontrar uma posição vazia.
- Se alcançar o final da tabela sem sucesso, retorna para a primeira posição.

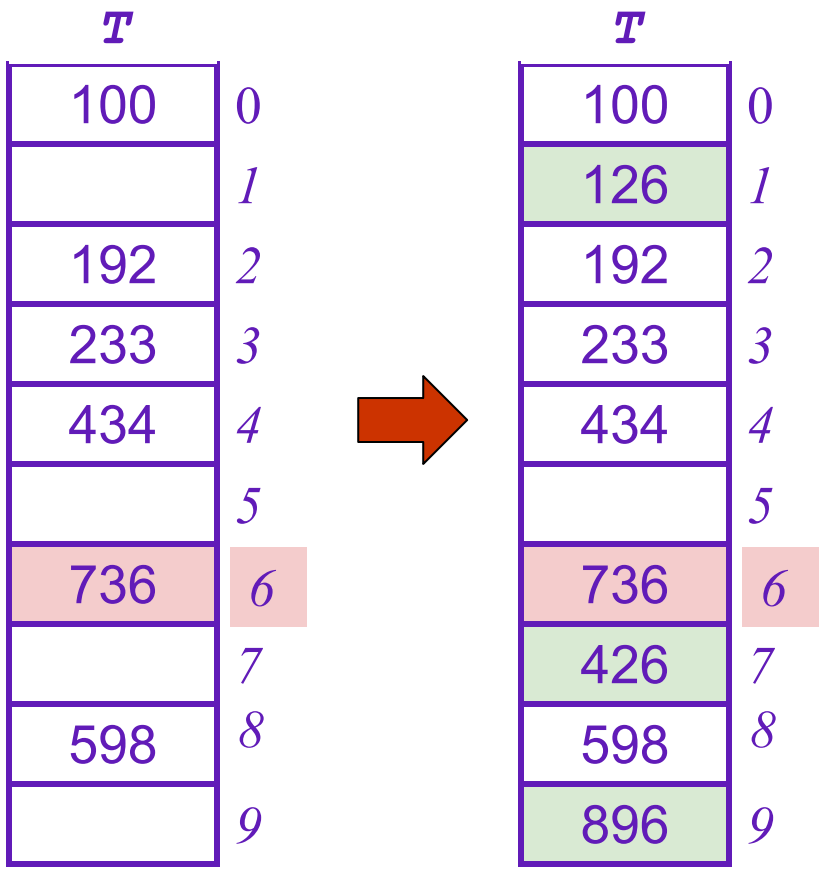


Tratamento de Colisões

$h(736) = h(426) = h(896) = h(126)$

Endereçamento aberto

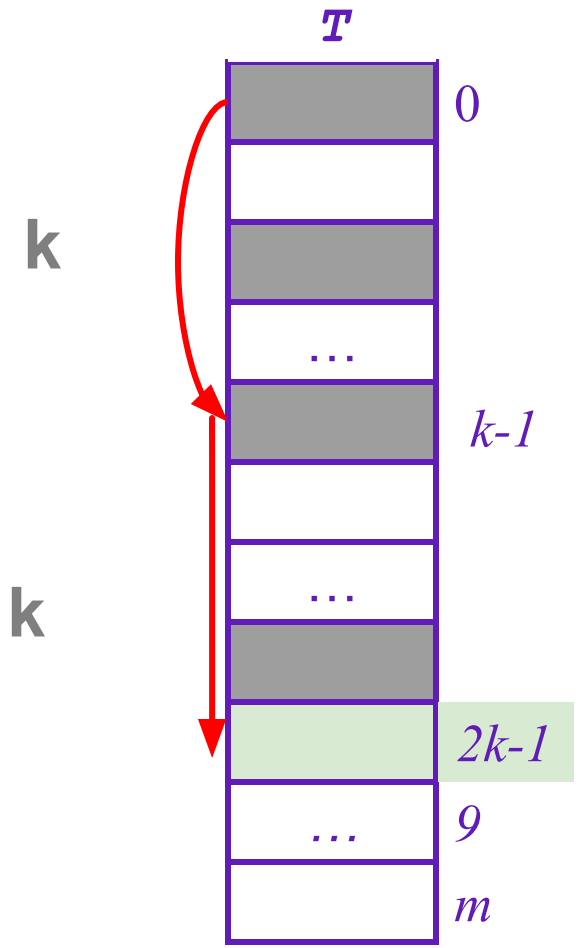
- A busca posição a posição de forma sequencial é chamada sondagem linear.
- Desvantagem: A técnica agrupa em posições vizinhas quando há várias colisões em uma mesma entrada.



Tratamento de Colisões

Endereçamento aberto

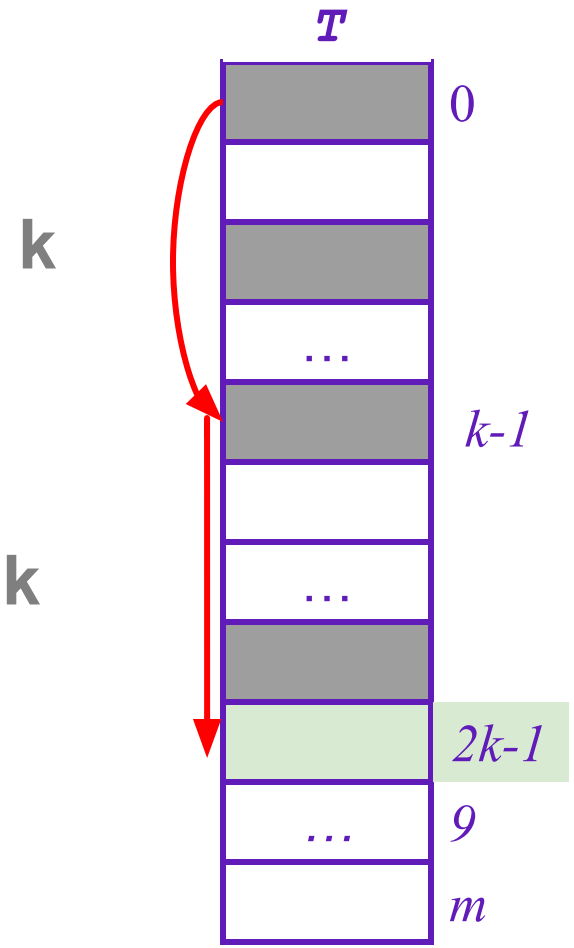
- Alternativa: incrementar a distância entre o ponto de colisão e inserção
  - h=item+1%m
  - h=item+5%m
  - h=item+k%m



Tratamento de Colisões

Endereçamento aberto

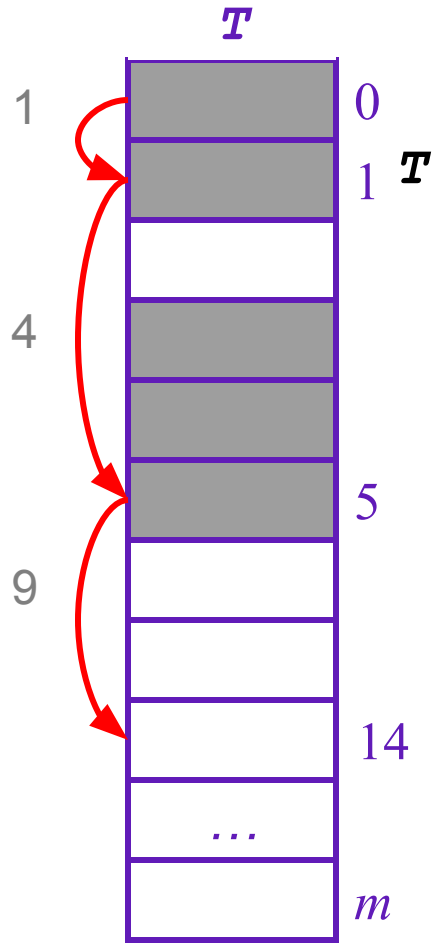
- O valor de m deve garantir que todas as entradas da tabela sejam acessadas pelo menos uma vez.
- Para evitar que partes da tabela não sejam acessadas, o valor de m deve ser um número primo.



Tratamento de Colisões

Endereçamento aberto

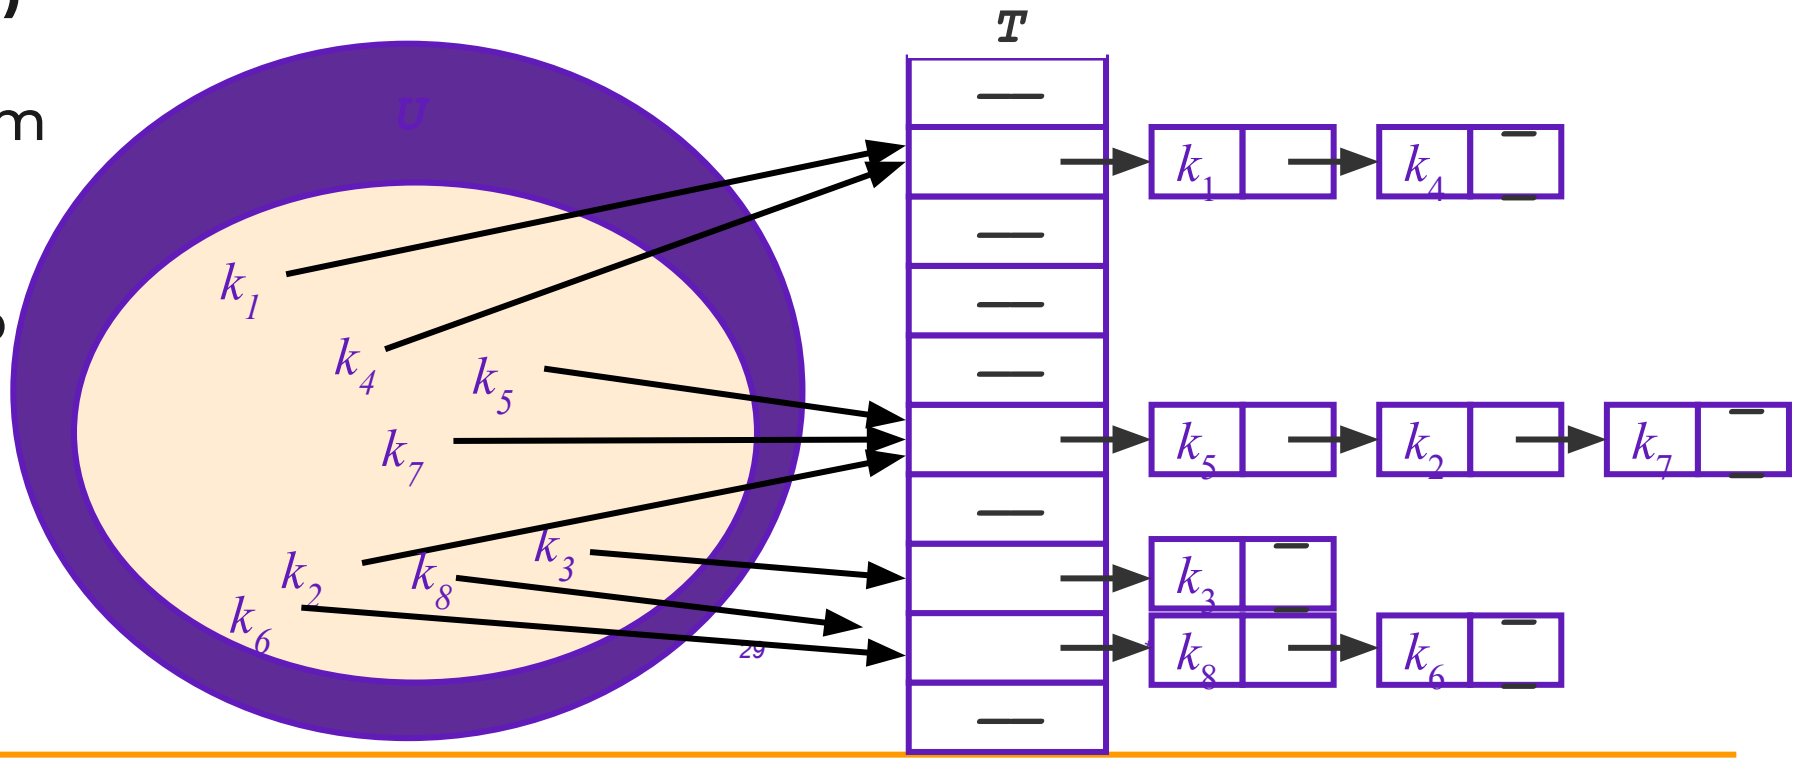
- Sondagem quadrática: os valores de k variam e são quadrados perfeitos sucessivos.
  - h(item)=(item+1)%m
  - h(item)=(item+4)%m
  - h(item)=(item+9)%m
  - h(item)=(item+16)%m
  - h(item)=(item + a^2)%m, a=1,2,3...K



Tratamento de Colisões

Encadeamento (Chaining)

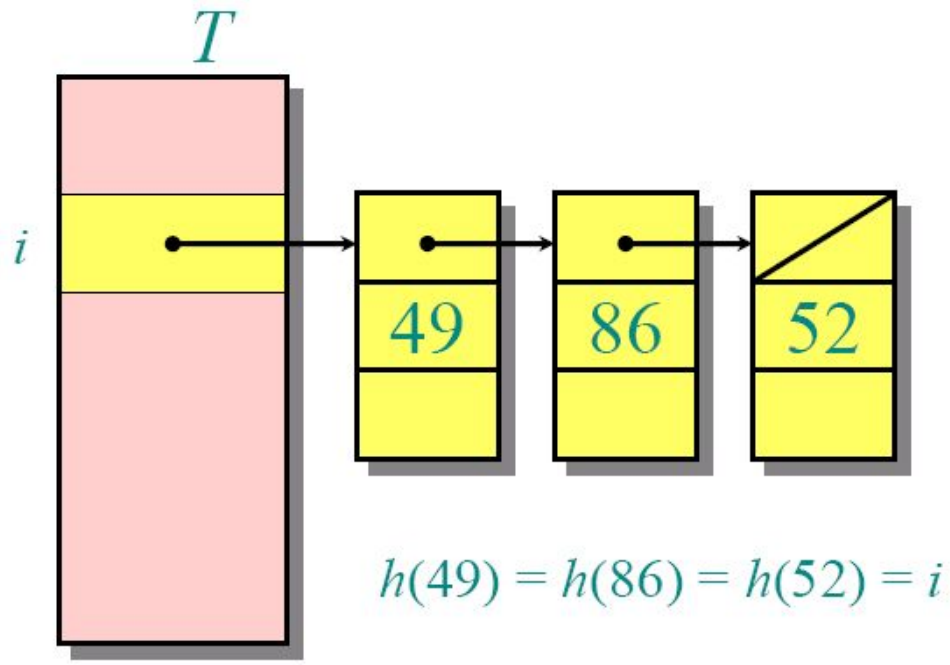
- As entradas referenciam uma coleção de itens.
- Por exemplo, inserindo elementos em uma sequência (lista ligada)



Tratamento de Colisões

Encadeamento (Chaining)

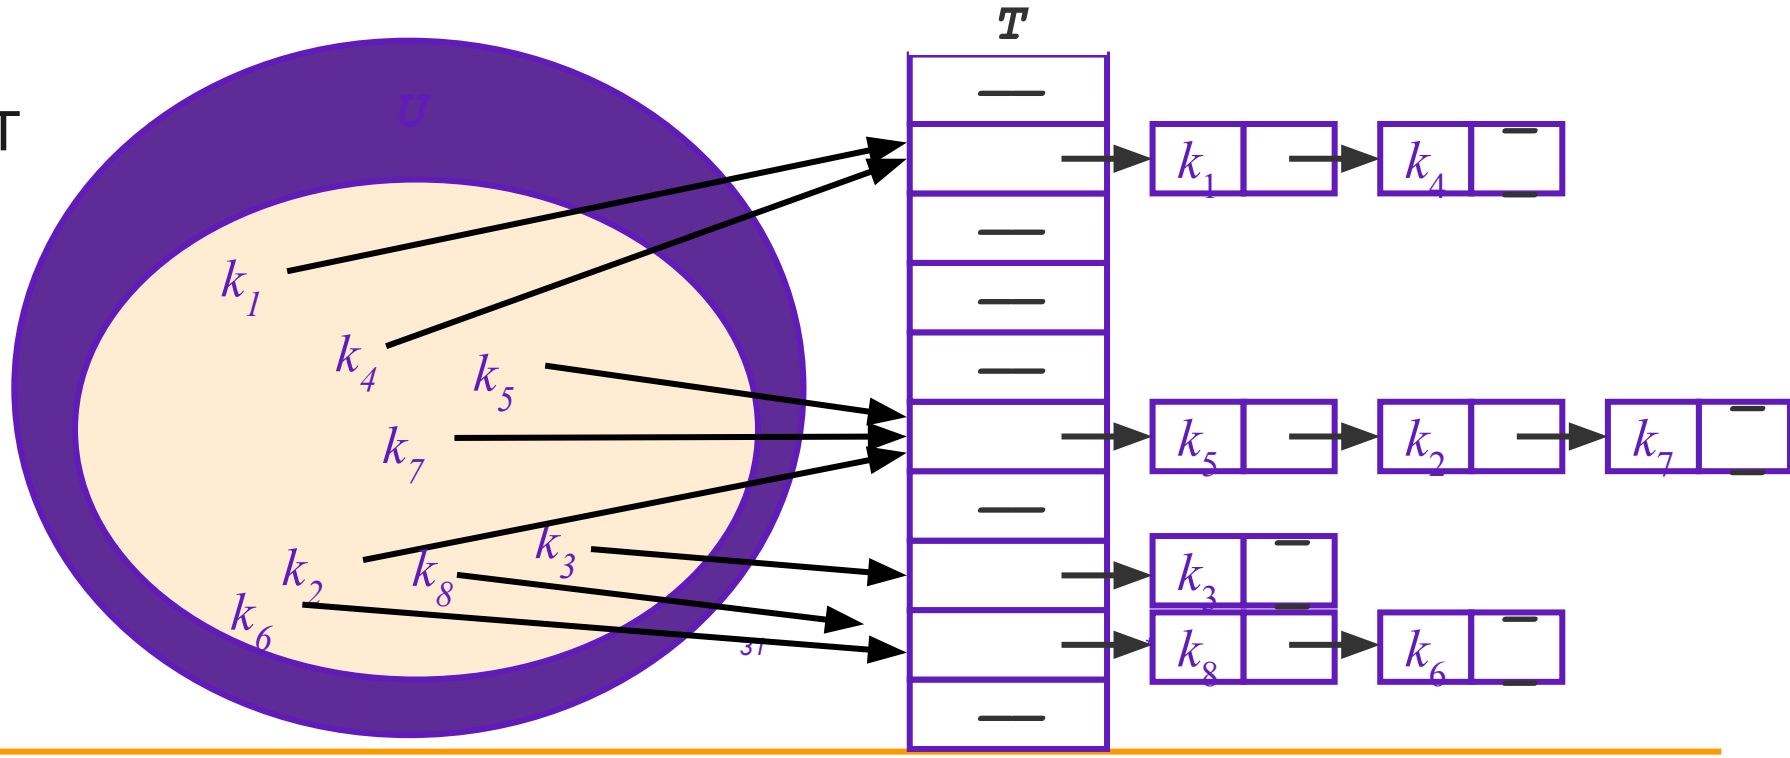
- Pior caso ocorre quando toda chave está atribuída ao mesmo slot
- Tempo de acesso Θ(n), se |K| =n

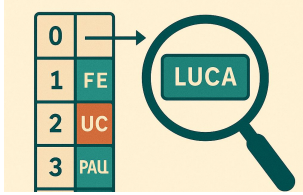


Tratamento de Colisões

Encadeamento (Chaining)

- Inserção em O(1), se o elemento não está em T
- Busca com pior caso proporcional ao tamanho da lista.

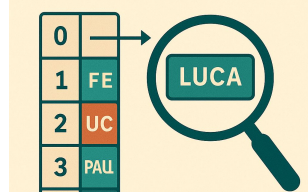




Tratamento de Colisões

Analisando o Encadeamento

- Suponha que cada chave é igualmente provável de ser atribuída a qualquer posição na tabela T.
- Para n chaves e m entradas em T, temos o fator de carregamento (load factor) definido como: $\alpha = n/m$: número médio de chaves por entrada em T.
- O custo médio de uma busca sem sucesso por uma chave k será: $O(1+\alpha)$
    - $O(1)$: tempo para calcular h(k).
    - $O(\alpha)$: tempo médio esperado para chegar ao final da lista na entrada T[h(k)].



Tratamento de Colisões

Analisando o Encadeamento

- O custo médio de uma busca com sucesso por uma chave k será O(1+α)

$$O(1+ \alpha/2)=O(1+ \alpha)$$

- Logo, o custo médio de uma busca (com ou sem sucesso) será O(1+α)
- Se o número de chaves n é proporcional ao número de entradas em T, teremos:

$$\alpha = n/m = O(m)/m=O(1) \text{ em média.}$$